


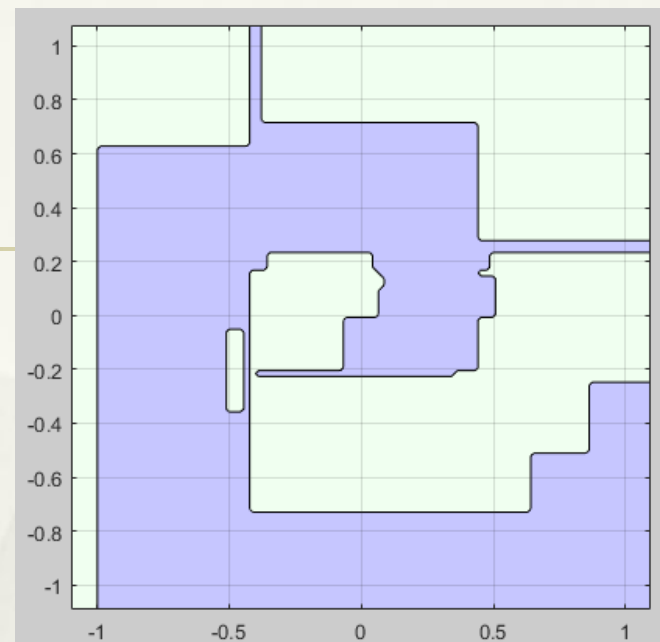
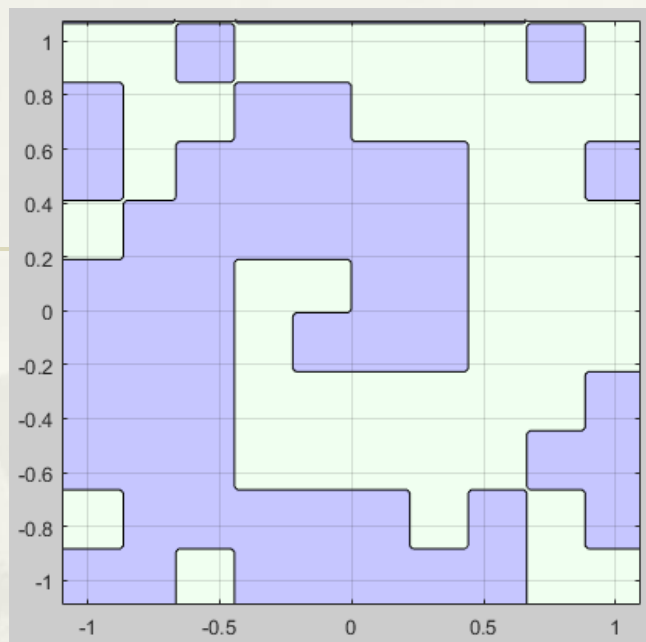



机器学习

Machine Learning

(三) 统计学习

何劲松
中国科学技术大学



iris数据

☞ Title: Iris Plants Database

☞ Sources:

- (a) Creator: R.A. Fisher
- (b) Donor: Michael Marshall
- (c) Date: July, 1988

☞ Attribute Information:

1. sepal length in cm
2. sepal width in cm
3. petal length in cm
4. petal width in cm
5. class:
 - Iris Setosa
 - Iris Versicolour
 - Iris Virginica


Iris数据集是常用的分类实验数据集，由Fisher收集整理。Iris也称鸢尾花卉数据集，是一种多重变量分析的数据集。数据集包含150个数据样本，分为3类，每类50个数据，每个数据包含4个属性。可通过花萼长度，花萼宽度，花瓣长度，花瓣宽度4个属性预测鸢尾花卉属于（Setosa, Versicolour, Virginica）三个种类中的哪一类。

22 5.1,3.7,1.5,0.4,Iris-setosa
23 4.6,3.6,1.0,0.2,Iris-setosa
24 5.1,3.3,1.7,0.5,Iris-setosa
25 4.8,3.4,1.9,0.2,Iris-setosa

1 5.1,3.5,1.4,0.2,Iris-setosa
2 4.9,3.0,1.4,0.2,Iris-setosa
3 4.7,3.2,1.3,0.2,Iris-setosa
4 4.6,3.1,1.5,0.2,Iris-setosa
5 5.0,3.6,1.4,0.2,Iris-setosa
6 5.4,3.9,1.7,0.4,Iris-setosa
7 4.6,3.4,1.4,0.3,Iris-setosa
8 5.0,3.4,1.5,0.2,Iris-setosa
9 4.4,2.9,1.4,0.2,Iris-setosa
10 4.9,3.1,1.5,0.1,Iris-setosa
11 5.4,3.7,1.5,0.2,Iris-setosa
12 4.8,3.4,1.6,0.2,Iris-setosa
13 4.8,3.0,1.4,0.1,Iris-setosa
14 4.3,3.0,1.1,0.1,Iris-setosa
15 5.8,4.0,1.2,0.2,Iris-setosa
16 5.7,4.4,1.5,0.4,Iris-setosa
17 5.4,3.9,1.3,0.4,Iris-setosa
18 5.1,3.5,1.4,0.3,Iris-setosa
19 5.7,3.8,1.7,0.3,Iris-setosa
20 5.1,3.8,1.5,0.3,Iris-setosa
21 5.4,3.4,1.7,0.2,Iris-setosa
22 5.1,3.7,1.5,0.4,Iris-setosa
23 4.6,3.6,1.0,0.2,Iris-setosa
24 5.1,3.3,1.7,0.5,Iris-setosa
25 4.8,3.4,1.9,0.2,Iris-setosa
26 5.0,3.0,1.6,0.2,Iris-setosa
27 5.0,3.4,1.6,0.4,Iris-setosa
28 5.2,3.5,1.5,0.2,Iris-setosa
29 5.2,3.4,1.4,0.2,Iris-setosa
30 4.7,3.2,1.6,0.2,Iris-setosa
31 4.8,3.1,1.6,0.2,Iris-setosa
32 5.4,3.4,1.5,0.4,Iris-setosa
33 5.2,4.1,1.5,0.1,Iris-setosa
34 5.5,4.2,1.4,0.2,Iris-setosa
35 4.9,3.1,1.5,0.1,Iris-setosa
36 5.0,3.2,1.2,0.2,Iris-setosa
37 5.5,3.5,1.3,0.2,Iris-setosa
38 4.9,3.1,1.5,0.1,Iris-setosa
39 4.4,3.0,1.3,0.2,Iris-setosa
40 5.1,3.4,1.5,0.2,Iris-setosa
41 5.0,3.5,1.3,0.3,Iris-setosa
42 4.5,2.3,1.3,0.3,Iris-setosa
43 4.4,3.2,1.3,0.2,Iris-setosa
44 5.0,3.5,1.6,0.6,Iris-setosa
45 5.1,3.8,1.9,0.4,Iris-setosa
46 4.8,3.0,1.4,0.3,Iris-setosa
47 5.1,3.8,1.6,0.2,Iris-setosa
48 4.6,3.2,1.4,0.2,Iris-setosa
49 5.3,3.7,1.5,0.2,Iris-setosa
50 5.0,3.3,1.4,0.2,Iris-setosa

51 7.0,3.2,4.7,1.4,Iris-versicolor
52 6.4,3.2,4.5,1.5,Iris-versicolor
53 6.9,3.1,4.9,1.5,Iris-versicolor
54 5.5,2.3,4.0,1.3,Iris-versicolor
55 6.5,2.8,4.6,1.5,Iris-versicolor
56 5.7,2.8,4.5,1.3,Iris-versicolor
57 6.3,3.3,4.7,1.6,Iris-versicolor
58 4.9,2.4,3.3,1.0,Iris-versicolor
59 6.6,2.9,4.6,1.3,Iris-versicolor
60 5.2,2.7,3.9,1.4,Iris-versicolor
61 5.0,2.0,3.5,1.0,Iris-versicolor
62 5.9,3.0,4.2,1.5,Iris-versicolor
63 6.0,2.2,4.0,1.0,Iris-versicolor
64 6.1,2.9,4.7,1.4,Iris-versicolor
65 5.6,2.9,3.6,1.3,Iris-versicolor
66 6.7,3.1,4.4,1.4,Iris-versicolor
67 5.6,3.0,4.5,1.5,Iris-versicolor
68 5.8,2.7,4.1,1.0,Iris-versicolor
69 6.2,2.2,4.5,1.5,Iris-versicolor
70 5.6,2.5,3.9,1.1,Iris-versicolor
71 5.9,3.2,4.8,1.8,Iris-versicolor
72 6.1,2.8,4.0,1.3,Iris-versicolor
73 6.3,2.5,4.9,1.5,Iris-versicolor
74 6.1,2.8,4.7,1.2,Iris-versicolor
75 6.4,2.9,4.3,1.3,Iris-versicolor
76 6.6,3.0,4.4,1.4,Iris-versicolor
77 6.8,2.8,4.8,1.4,Iris-versicolor
78 6.7,3.0,5.0,1.7,Iris-versicolor
79 6.0,2.9,4.5,1.5,Iris-versicolor
80 5.7,2.6,3.5,1.0,Iris-versicolor
81 5.5,2.4,3.8,1.1,Iris-versicolor
82 5.5,2.4,3.7,1.0,Iris-versicolor
83 5.8,2.7,3.9,1.2,Iris-versicolor
84 6.0,2.7,5.1,1.6,Iris-versicolor
85 5.4,3.0,4.5,1.5,Iris-versicolor
86 6.0,3.4,4.5,1.6,Iris-versicolor
87 6.7,3.1,4.7,1.5,Iris-versicolor
88 6.3,2.3,4.4,1.3,Iris-versicolor
89 5.6,3.0,4.1,1.3,Iris-versicolor
90 5.5,2.5,4.0,1.3,Iris-versicolor
91 5.5,2.6,4.4,1.2,Iris-versicolor
92 6.1,3.0,4.6,1.4,Iris-versicolor
93 5.8,2.6,4.0,1.2,Iris-versicolor
94 5.0,2.3,3.3,1.0,Iris-versicolor
95 5.6,2.7,4.2,1.3,Iris-versicolor
96 5.7,3.0,4.2,1.2,Iris-versicolor
97 5.7,2.9,4.2,1.3,Iris-versicolor
98 6.2,2.9,4.3,1.3,Iris-versicolor
99 5.1,2.5,3.0,1.1,Iris-versicolor
100 5.7,2.8,4.1,1.3,Iris-versicolor

101 6.3,3.3,6.0,2.5,Iris-virginica
102 5.8,2.7,5.1,1.9,Iris-virginica
103 7.1,3.0,5.9,2.1,Iris-virginica
104 6.3,2.9,5.6,1.8,Iris-virginica
105 6.5,3.0,5.8,2.2,Iris-virginica
106 7.6,3.0,6.6,2.1,Iris-virginica
107 4.9,2.5,4.5,1.7,Iris-virginica
108 7.3,2.9,6.3,1.8,Iris-virginica
109 6.7,2.5,5.8,1.8,Iris-virginica
110 7.2,3.6,6.1,2.5,Iris-virginica
111 6.5,3.2,5.1,2.0,Iris-virginica
112 6.4,2.7,5.3,1.9,Iris-virginica
113 6.8,3.0,5.5,2.1,Iris-virginica
114 5.7,2.5,5.0,2.0,Iris-virginica
115 5.8,2.8,5.1,2.4,Iris-virginica
116 6.4,3.2,5.3,2.3,Iris-virginica
117 6.5,3.0,5.5,1.8,Iris-virginica
118 7.7,3.8,6.7,2.2,Iris-virginica
119 7.2,6.6,9.2,3.3,Iris-virginica
120 6.0,2.2,5.0,1.5,Iris-virginica
121 6.9,3.2,5.7,2.3,Iris-virginica
122 5.6,2.8,4.9,2.0,Iris-virginica
123 7.2,2.8,6.7,2.0,Iris-virginica
124 6.3,2.7,4.9,1.8,Iris-virginica
125 6.7,3.3,5.7,2.1,Iris-virginica
126 7.2,3.2,6.0,1.8,Iris-virginica
127 6.2,2.8,4.8,1.8,Iris-virginica
128 6.1,3.0,4.9,1.8,Iris-virginica
129 6.4,2.8,5.6,2.1,Iris-virginica
130 7.2,3.0,5.8,1.6,Iris-virginica
131 7.4,2.8,6.1,1.9,Iris-virginica
132 7.9,3.8,6.4,2.0,Iris-virginica
133 6.4,2.8,5.6,2.2,Iris-virginica
134 6.3,2.8,5.1,1.5,Iris-virginica
135 6.1,2.6,5.6,1.4,Iris-virginica
136 7.7,3.0,6.1,2.3,Iris-virginica
137 6.3,3.4,5.6,2.4,Iris-virginica
138 6.4,3.1,5.5,1.8,Iris-virginica
139 6.0,3.0,4.8,1.8,Iris-virginica
140 6.9,3.1,5.4,2.1,Iris-virginica
141 6.7,3.1,5.6,2.4,Iris-virginica
142 6.9,3.1,5.1,2.3,Iris-virginica
143 5.8,2.7,5.1,1.9,Iris-virginica
144 6.8,3.2,5.9,2.3,Iris-virginica
145 6.7,3.3,5.7,2.5,Iris-virginica
146 6.7,3.0,5.2,2.3,Iris-virginica
147 6.3,2.5,5.0,1.9,Iris-virginica
148 6.5,3.0,5.2,2.0,Iris-virginica
149 6.2,3.4,5.4,2.3,Iris-virginica
150 5.9,3.0,5.1,1.8,Iris-virginica




取iris数据的第1维和第2维特征，观察第1类和第2类样本在空间的分布。


模式识别的**分类问题**是根据识别对象**特征**的**观察值**，并常以**空间划分**的方法将其分到某个类别中去。（傅京孙）

线性可分

寻找到一个判别函数 $f(x)$ ，使得对于“+”类样本的值代入 $f(x)$ 都有 $f(x) > 0$ ，“o”类样本值代入 $f(x)$ 都有 $f(x) < 0$ 。或者，

$$\begin{cases} \text{if } f(x) > 0, \text{ then } x \in \omega_+ \\ \text{if } f(x) < 0, \text{ then } x \in \omega_o \end{cases}$$







取iris数据的第1维和第2维特征，观察第2类和第3类样本在空间的分布。

在2维空间中，第2类和第3类样本有重叠，不可分。

取iris数据的第1, 2, 3维特征，观察第2类和第3类样本在空间的分布。

在3维空间中，第2类和第3类样本线性不可分（非线性）。





取iris数据的第1, 2, 3维特征, 观察3类样本在3维空间的分布。

讨论:

- 1) 对于分类问题, 机器学习的目标是找到各类样本之间的分解面?
- 2) 特征映射和特征空间的维度。
- 3) 样本的空间分布: 几何? 概率? 距离?
- 4) 分类和预测, 以及正确率 (or 错误率)。

设想: 如果我们利用已知样本 (已经发生的事件/训练样本) 估计出一种可用于判断的概率函数, 那么, 我们对于未发生事件 (待识别样本) 就可以做出一种概率意义上的判断 (分类)。

要求:

- (1) 各类别总体的概率分布是已知的, 即 $P(\omega_+)$, $P(\omega_-)$ 已知。
- (2) 要决策分类的类别数是一定的。

1.基于最小错误率的Bayes决策

- * Bayes公式:

$$P(A|B)P(B) = P(B|A)P(A)$$

- * 换符号:

$$A \rightarrow x; B \rightarrow \omega$$

$$P(x|\omega)P(\omega) = P(\omega|x)P(x)$$

- * 对于二分类问题:

$$P(x|\omega_1)P(\omega_1) = P(\omega_1|x)P(x) \quad \text{和} \quad P(x|\omega_2)P(\omega_2) = P(\omega_2|x)P(x)$$

示例：

例：癌细胞识别。

假设要识别的细胞已经做过处理。抽取了 d 个表示细胞基本特性的特征，成为一个 d 维空间向量 x ($x \in R^d$)。识别的目的是要将 x 分类为正常细胞或异常细胞。令 ω_1 表示正常， ω_2 表示异常。

根据医院细胞病理检查的大量统计资料，可以对某一地区正常细胞出现的比例做出估计。这相当于在识别前已知正常状态概率 $P(\omega_1)$ 和异常状态概率 $P(\omega_2)$ 。

$p(x|\omega_1)$ 是正常状态下细胞特征（光密度）观察 x 的类条件概率密度；

$p(x|\omega_2)$ 是异常状态下细胞特征（光密度）观察 x 的类条件概率密度。


那么，由Bayes公式

$$P(\omega_i|x) = \frac{p(x|\omega_i)P(\omega_i)}{\sum_{j=1}^C p(x|\omega_j)P(\omega_j)}$$

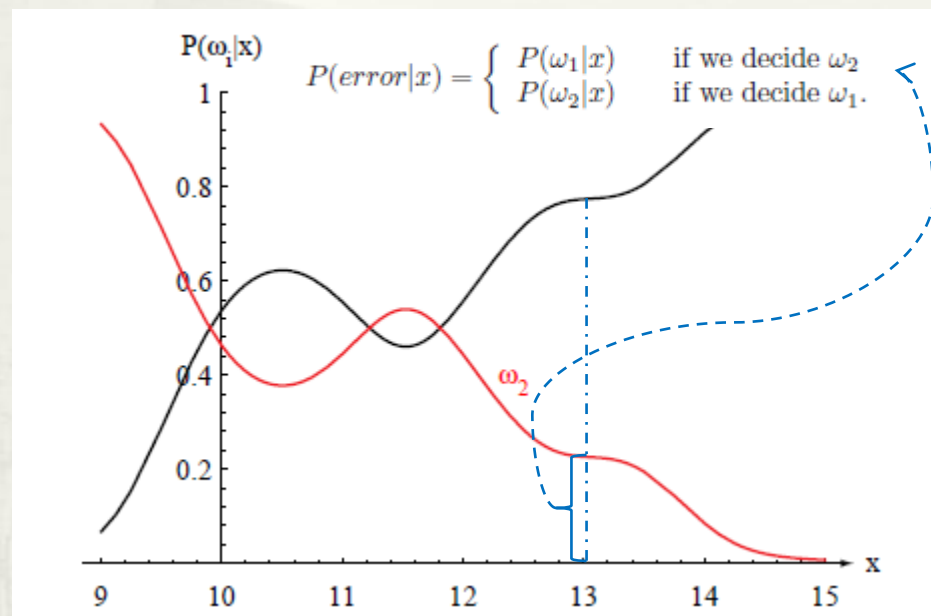
可得到条件概率 $P(\omega_i|x)$ ，即后验概率。

2. Bayes决策规则和错误率

可观察



若 $P(\omega_1|x) > P(\omega_2|x)$, 则将 x 归类为 ω_1 ,
反之, 把 x 归类于异常状态 ω_2 。



If $P(\omega_i|x) = \max_j P(\omega_j|x)$, then $x \in \omega_i$

If $p(x|\omega_i)P(\omega_i) = \max_j p(x|\omega_j)P(\omega_j)$, then $x \in \omega_i$

If $l(x) = \frac{p(x|\omega_1)}{p(x|\omega_2)} \geq \frac{P(\omega_2)}{P(\omega_1)}$ then $x \in \{\omega_1, \omega_2\}$

If $h(x) = -\ln[l(x)] = -\ln p(x|\omega_1) + \ln p(x|\omega_2)$
 $\geq \ln \left(\frac{P(\omega_1)}{P(\omega_2)} \right)$, then $x \in \{\omega_1, \omega_2\}$

错误率


以1维情况来演示：按照这种Bayes决策规则进行分类可使错误率最小。

所谓错误率是指平均错误率，以 $P(e)$ 表示，其定义为

$$P(e) = \int_{-\infty}^{+\infty} p(e, x) dx = \int_{-\infty}^{+\infty} p(e|x)p(x) dx$$

对于2类问题，由决策规则可知

$$p(e|x) = \begin{cases} p(\omega_1|x), & \text{当 } p(\omega_2|x) > p(\omega_1|x) \\ p(\omega_2|x), & \text{当 } p(\omega_1|x) > p(\omega_2|x) \end{cases}$$



令 t 为两类分界面。当特征 x 是一维时， t 为 x 轴上一个点，且 t 将 x 轴分为2个区域 R_1 和 R_2 。于是

$$\begin{aligned} P(e) &= \int_{-\infty}^t p(\omega_2|x)p(x) dx + \int_t^{+\infty} p(\omega_1|x)p(x) dx \\ &= \int_{-\infty}^t p(x|\omega_2)p(\omega_2) dx + \int_t^{+\infty} p(x|\omega_1)p(\omega_1) dx \\ &= P(\omega_2)P_2(e) + P(\omega_1)P_1(e) \end{aligned}$$

决策规则实际上是对每个 x 都使 $p(e|x)$ 取最小，即 $P(e)$ 最小。

3.基于最小风险的Bayes决策

使**错误率** $P(e)$ 达到最小是重要的，但实际上需要考虑一个比错误率更为广泛的概念——**风险**。而风险又是和损失函数紧密相连的。

在决策论中，称采取的决定为决策或行动。所有可能采取的决策组合的集合称决策空间或行动空间，以 \mathcal{A} 表示。

每个决策或行动都将带来一定的损失，它通常是决策和自然状态的函数。

状态 损失 决策	自然状态					
	ω_1	ω_2	...	ω_j	...	ω_C
α_1	$\lambda(\alpha_1, \omega_1)$	$\lambda(\alpha_1, \omega_2)$...	$\lambda(\alpha_1, \omega_j)$...	$\lambda(\alpha_1, \omega_C)$
α_2	$\lambda(\alpha_2, \omega_1)$	$\lambda(\alpha_2, \omega_2)$...	$\lambda(\alpha_2, \omega_j)$...	$\lambda(\alpha_2, \omega_C)$
...
α_i	$\lambda(\alpha_i, \omega_1)$	$\lambda(\alpha_i, \omega_2)$...	$\lambda(\alpha_i, \omega_j)$...	$\lambda(\alpha_i, \omega_C)$
...
α_a	$\lambda(\alpha_a, \omega_1)$	$\lambda(\alpha_a, \omega_2)$...	$\lambda(\alpha_a, \omega_j)$...	$\lambda(\alpha_a, \omega_C)$

最小风险Bayes决策规则

令期望风险为

$$R = \int R(\alpha(x)|x) p(x) dx$$

我们希望：要求采取的一系列决策行动 $\alpha(x)$ 使期望风险 R 最小。最小风险Bayes决策规则为

$$\text{如果 } R(\alpha_k|x) = \min_{i=1,2,\dots,a} R(\alpha_i|x), \text{ 则 } \alpha = \alpha_k$$

对于实际问题，最小风险 Bayes决策可按下列步骤进行：

- 1) 根据Bayes公式计算出后验概率 $P(\omega_j|x)$
- 2) 利用后验概率及决策表，计算条件风险 $R(\alpha_i|x) = \sum_{j=1}^C \lambda(\alpha_i|\omega_j)P(\omega_j|x)$
- 3) 对得到的 a 个条件风险值 $R(\alpha_i|x)$ 进行比较，找出使条件风险最小的决策 α_k ，即

$$R(\alpha_k|x) = \min_{i=1,2,\dots,a} R(\alpha_i|x)$$

则 α_k 就是最小风险Bayes决策。

4.参数估计决策

对于类条件概率密度函数 $p(x|\omega_i)$ ，若已经知道，则直接采用Bayes决策规则；若不知道，但知道 $p(x|\omega_i)$ 的分布形式，则可采用参数估计的方法。

在连续概率密度函数中，研究较透彻的是多元正态分布。其原因是

- 1) 物理上的合理性；
- 2) 数学上比较简便。

单变量正态分布概率密度函数：

$$p(x) = \frac{1}{\sqrt{2\pi} \sigma} \exp \left\{ -\frac{1}{2} \left(\frac{x - \mu}{\sigma} \right)^2 \right\}$$

多元正态分布的概率密度函数：

$$p(X) = \frac{1}{(2\pi)^{d/2} |\Sigma|^{1/2}} \exp \left\{ -\frac{1}{2} (X - \vec{\mu})^T \Sigma^{-1} (X - \vec{\mu}) \right\}$$

Σ 是 $d \times d$ 维协方差矩阵， $|\Sigma|$ 是 Σ 的行列式， T 表示转置， $\vec{\mu} = E\{X\}$ ，

$$\Sigma = E \{ (X - \vec{\mu}) (X - \vec{\mu})^T \}$$

多元正态概率型下最小错误率Bayes判别函数和决策面

似然函数的对数：

$$g_i(X) = -\frac{1}{2}(X - U_i)^T \Sigma_i^{-1}(X - U_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma_i| + \ln[P(\omega_i)]$$

决策面方程：

$$g_i(X) = g_j(X)$$

我们分三种情况予以讨论：

- ① $\Sigma_i = \sigma^2 I, \quad i = 1, 2, \dots, C$
- ② $\Sigma_i = \Sigma$
- ③ 各类协方差阵不相等。

第一种情况: $\Sigma_i = \sigma^2 I, i = 1, 2, \dots, C$

即, 每类的协方差矩阵都相等, 而且类内各特征相互独立, 具有相等的方差 σ^2 。

1) 若先验概率 $P(\omega_i) \neq P(\omega_j)$, 此时 $\Sigma_i = \begin{pmatrix} \sigma^2 & \dots & 0 \\ \vdots & \ddots & \vdots \\ 0 & \dots & \sigma^2 \end{pmatrix}; |\Sigma_i| = \sigma^{2d}; \Sigma_i^{-1} = \frac{1}{\sigma^2} I$

$$g_i(X) = -\frac{1}{2\sigma^2} (X - U_i)^T (X - U_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln \sigma^{2d} + \ln[P(\omega_i)]$$

$$g_i(X) = -\frac{1}{2\sigma^2} (X - U_i)^T (X - U_i) + \ln[P(\omega_i)]$$

与类别无关

$$(X - U_i)^T (X - U_i) = \|X - U_i\|^2 = \sum_{j=1}^d (x_j - \mu_{ij})^2 \quad i = 1, 2, \dots, C$$

欧氏距离平方

2) 若先验概率 $P(\omega_i) = P(\omega_j)$, 此时

$$g_i(X) = -\frac{1}{2\sigma^2} (X - U_i)^T (X - U_i)$$

为 X 的二次函数, 但 $X^T X$ 与 i 无关, 可忽略。故判决函数为线性函数。

只需要计算 $\|X - U_i\|^2$, 取min即可。称为**最小距离分类器**。

第二种情况: $\Sigma_i = \Sigma$

即, 各类协方差矩阵都相等, Σ 与 i 无关。

此时, $g_i(X)$ 可简化为:

$$g_i(X) = -\frac{1}{2}(X - U_i)^T \Sigma^{-1}(X - U_i) + \ln[P(\omega_i)]$$

若先验概率都相等, 则为Mahalanobis距离平方。

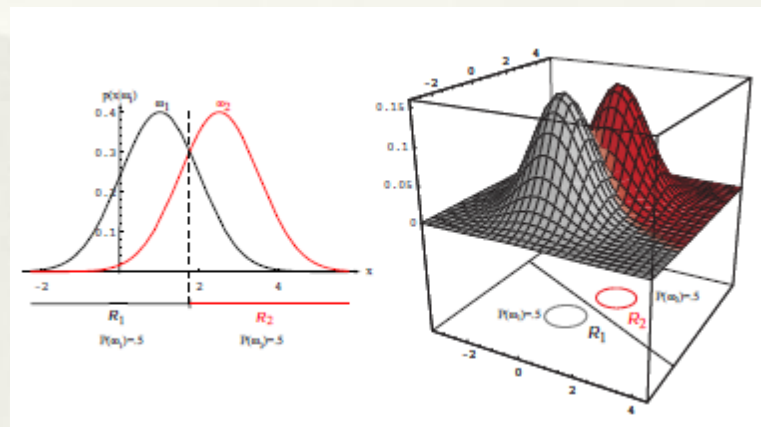
忽略与 i 无关的 $X^T \Sigma^{-1} X$ 项, 则判别函数可写成

$$g_i(X) = W_i^T X + W_{i0}$$

$$\text{其中, } W_i = \Sigma^{-1} U_i$$

$$W_{i0} = -\frac{1}{2} U_i^T \Sigma^{-1} U_i + \ln[P(\omega_i)]$$

仍是 X 的线性函数。因此, 决策面仍是一个超平面。



第三种情况：各类协方差阵不相等。

$$\begin{aligned} g_i(X) &= -\frac{1}{2}(X - U_i)^T \Sigma_i^{-1}(X - U_i) - \frac{d}{2} \ln(2\pi) - \frac{1}{2} \ln|\Sigma_i| + \ln[P(\omega_i)] \\ &= -\frac{1}{2}(X - U_i)^T \Sigma_i^{-1}(X - U_i) - \frac{1}{2} \ln|\Sigma_i| + \ln[P(\omega_i)] \\ &= X^T W_i X + W_{i1}^T X + W_{i0} \end{aligned}$$

其中,

$$W_i = -\frac{1}{2} \Sigma_i^{-1}$$

$$W_{i1} = \Sigma_i^{-1} U_i$$

$$W_{i0} = -\frac{1}{2} U_i^T \Sigma_i^{-1} U_i - \frac{1}{2} \ln|\Sigma_i| + \ln P(\omega_i)$$










此时，判决函数为 X 的二次型。若决策区域 \mathcal{R}_1 与 \mathcal{R}_2 相邻，则判决面应满足

$$g_i(X) - g_j(X) = 0$$


$$\text{即, } X^T (W_i - W_j) X + (W_{i1} - W_{j1})^T X + W_{i0} - W_{j0} = 0$$

为超二次曲面。随 $\Sigma_i, U_i, P(\omega_i)$ 不同而是超球面，超椭球面，超抛物面，超双曲面，或超平面。

第三种情况下的边界示意



先验概率变化，决策边界会移动。



5. 错误率估计和边界

Chernoff上界:

利用不等式: $\min[a, b] \leq a^\beta b^{1-\beta}$

($a, b \geq 0$, 且 $0 \leq \beta \leq 1$)

有

$$P(e) \leq P^\beta(\omega_1)P^{1-\beta}(\omega_2) \int p^\beta(x|\omega_1)p^{1-\beta}(x|\omega_2)dx$$

解得

$$\int p^\beta(x|\omega_1)p^{1-\beta}(x|\omega_2)dx = e^{-k(\beta)}$$

正态分布时,

$$k(\beta) = \frac{\beta(1-\beta)}{2} (\mu_2 - \mu_1)^t [\beta \Sigma_1 + (1-\beta)\Sigma_2]^{-1} (\mu_2 - \mu_1) + \frac{1}{2} \ln \frac{|\beta \Sigma_1 + (1-\beta)\Sigma_2|}{|\Sigma_1|^\beta |\Sigma_2|^{1-\beta}}$$

Bhattacharyya上界:

$$\text{取 } \beta = \frac{1}{2}$$

$$P(e) \leq \sqrt{P(\omega_1)P(\omega_2)} \int \sqrt{p(x|\omega_1)p(x|\omega_2)} dx \\ = \sqrt{P(\omega_1)P(\omega_2)} e^{-k(1/2)}$$

正态分布时,

$$k(1/2) = \frac{1}{8} (\mu_2 - \mu_1)^t \left[\frac{\Sigma_1 + \Sigma_2}{2} \right]^{-1} (\mu_2 - \mu_1) + \frac{1}{2} \ln \frac{\left| \frac{\Sigma_1 + \Sigma_2}{2} \right|}{\sqrt{|\Sigma_1||\Sigma_2|}}$$

注: 对于偏离高斯分布太远的分布, 这些上界不能说明什么问题。