

机器学习


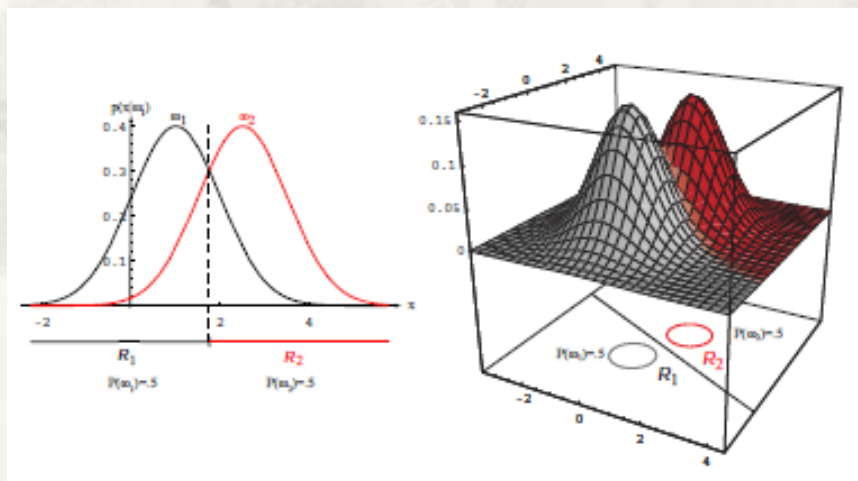
Machine Learning

(四) 非参数学习


何劲松
中国科学技术大学


6. 非参数估计方法

- * 参数估计方法的前提是假设类条件概率密度函数 $p(x|\omega_i)$ 的形式已经知道。
- * 在多数模式分类问题中，往往不知道 $p(x|\omega_i)$ 的形式，常见的函数形式并不适合实际的真正密度分布。
- * 或者说，经典的参数估计大多适合用于平滑变化和单峰突出的密度分布，只有一个极大值。实际概率分布却是多峰的。



6.1 非参数估计的基本概念

- * 非参数估计的任务是利用抽样试验的训练集 X 估计样本 x 的总体概率分布密度 $p(x|X)$ 。如果训练集 X 中的样本数目 n 足够大，那么 $p(x|X)$ 应该非常接近真实的分布密度 $p(x)$ 。
- * 完成这种训练的基本思想是：每个样本 $x_k (k = 1, 2, \dots, n)$ 对总体概率分布密度 $p(x)$ 都有一定贡献。把 n 个训练样本的贡献叠加起来，就得到总体分布密度估计。 $\hat{p}(x) = p(x|X)$
- * 样本数目 n 越多，估计的曲线越平滑，也越接近真实的概率分布曲线。
- * 例如矩形窗函数：（也可以是内插函数 ）



6.2 非参数估计方法

令样本 x 落入区域 \mathcal{R} 里的概率 p 为

$$p = \int_{\mathcal{R}} p(x) dx \quad (1)$$

当彼此独立地抽取 n 个试验，得到 n 个训练样本 x_1, x_2, \dots, x_n ，它们分别以 $p(x_1), p(x_2), \dots, p(x_n)$ 出现。

其中有 k 个样本落入这个区域 \mathcal{R} 里的概率服从二项式分布。即

$$p_k = \binom{n}{k} p^k (1-p)^{n-k} \quad (2)$$

式中

$$\binom{n}{k} = \frac{n!}{k! (n-k)!} \quad (3)$$

由于 x_k 是随机抽取的，所以落入区域 \mathcal{R} 里的数目 k 也是随机的。它的期望值

$$E(k) = np \quad (4)$$

所以 p 的一个估计为

$$\hat{p} \approx \frac{k}{n} \quad (5)$$

如果区域 \mathcal{R} 足够小，以至于概率密度 $p(x)$ 在 \mathcal{R} 里可以近似地认为恒定不变。那么由(1)式可得

$$p = \int_{\mathcal{R}} p(x) dx \approx p(x) \cdot V \quad (6)$$

其中 V 为区域 \mathcal{R} 所占有的空间体积。

利用(5)和(6)，可有

$$\hat{p} = \hat{p}(x) V \approx \frac{k}{n} \quad (7)$$

所以

$$\hat{p}(x) \approx \frac{k/n}{V} \quad (8)$$

对于(8)式，

A. 若区域 \mathcal{R} 的体积 V 是固定的，训练样本 n 越来越多，且假定 k/n 随 n 的增大而收敛，那么我们就只能得到 $p(x)$ 在 \mathcal{R} 上的一个平均估计，即

$$\frac{\hat{p}}{V} = \frac{\int_{\mathcal{R}} p(x) dx}{\int_{\mathcal{R}} dx}$$

B. 若训练样本数目 n 是固定的，使 \mathcal{R} 的区域不断缩小，即，令趋于0，就会发生2种情况：

① \mathcal{R} 中不再有任何样本；

② 碰巧 \mathcal{R} 里有1个或 n 个重合的样本。

这两种情况分别对应 $\hat{p}(x) = 0$ 和 $\hat{p}(x) = \infty$ ，显然应该避免。为此要加限制条件。即

$$<1> \quad \lim_{n \rightarrow \infty} V_n = 0$$

$$<2> \quad \lim_{n \rightarrow \infty} k_n = \infty$$

$$<3> \quad \lim_{n \rightarrow \infty} \left(\frac{k_n}{n} \right) = 0$$

满足上述三个条件的区域序列的选择方法，存在2个基本技术途径：

其一：把包含 x 点的区域序列 $\{\mathcal{R}_n\}$ 选为训练样本数目 n 的函数，并且对应空间体积 V_n 随 n 增大而减小。

⇒ Parzen窗函数法的思想

$$\text{例如，令 } V_n = \frac{V_1}{\sqrt{n}}$$

其二，把 k_n 选为训练样本数目 n 的函数。

$$\text{例如，令 } k_n = \sqrt{n}$$

然后选择包含 x 点的区域体积，使之不断增大，直到正好包含 k_n 个样本。那么该区域体积可用作 x 点的密度估计。

⇒ k_n 近邻法的思想

6.3 Parzen窗法

假定围绕 x 点的区域 \mathcal{R}_n 为一超立方体，其边长为 h_n ， d 为特征空间的维数。则

$$V_n = h_n^d \quad (9)$$

为考查 x_k 是否落入超立方体内，则要检查向量 $x - x_k$ 的每一个分量是否小于 $h_n/2$ 。
定义窗函数

$$\phi(u) = \begin{cases} 1, & |u_j| \leq \frac{1}{2}, j = 1, 2, \dots, d \\ 0, & \text{其它} \end{cases} \quad (10)$$

可见， $\phi(u)$ 的体积为1。

若令

$$u = \frac{x - x_k}{h_n} \quad (11)$$

则窗函数变为

$$\phi\left(\frac{x - x_k}{h_n}\right) = \begin{cases} 1, & |x - x_k|_j \leq \frac{1}{2}, j = 1, 2, \dots, d \\ 0, & \text{其它} \end{cases} \quad (12)$$

显然

$$k_n = \sum_{k=1}^n \phi\left(\frac{x - x_k}{h_n}\right) \quad (13)$$

于是

$$\hat{p}_n(x) = \frac{1}{n} \sum_{k=1}^n \frac{1}{V_n} \phi\left(\frac{x - x_k}{h_n}\right) \quad (14)$$

且满足

$$\phi(u) \geq 0, \quad \int \phi(u) du = 1$$

以及

$$\int \hat{p}_n(x) dx = \int \frac{1}{n} \sum_{k=1}^n \frac{1}{V_n} \phi\left(\frac{x - x_k}{h_n}\right) dx = \frac{1}{n} \sum_{k=1}^n \int \phi(u) du = \frac{1}{n} \cdot n = 1$$

(14)式即为Parzen窗估计方法。

注意： h_n 对 $\hat{p}(x)$ 有重大影响。

6.4 窗函数的选择

(1)矩形窗函数


$$\phi(u) = \begin{cases} 1, & |u_j| \leq \frac{1}{2}, j = 1, 2, \dots, d \\ 0, & \text{其它} \end{cases}$$

(2)正态窗函数

$$\phi(u) = \frac{1}{\sqrt{2\pi}} \exp\left\{-\frac{1}{2}u^2\right\}$$

(3)指数窗函数

$$\phi(u) = \exp\{-|u|\}$$




6.5 Parzen窗函数法程序实现

```
function D = parzen(train_features, train_targets, hn, region)
% Classify using the Parzen windows algorithm
% Inputs:
%         features      - Train features
%         targets       - Train targets
%         hn            - Normalizing factor for h
%         region        - Decision region vector: [-x x -y y number_of_points]
% Outputs
%         D             - Decision suface


N = region(5);      %Number of points on the grid
x = ones(N,1) * linspace (region(1),region(2),N);
y = linspace (region(3),region(4),N)' * ones(1,N);
Uc = unique(train_targets);
V = zeros(length(Uc), N, N);
x_i = train_features;
for j = 1:length(Uc),
    indices = find(train_targets == Uc(j));
    P(j) = length(indices)/size(x_i,2);
    n = length(indices);
    for i = 1:n,
        temp = (x - x_i(1,indices(i))).^2 + (y - train_features(2,indices(i))).^2;
        V(j,,:,i) = squeeze(V(j,,:,i)) + phi(temp./hn);
        if (i/50 == floor(i/50)),
            disp(['Finished ' num2str(i) ' iterations out of ' num2str(n) ' iterations.'])
        end
    end
end
V(j,,:) = V(j,,:) / sum(sum(squeeze(V(j,,:,i)))));
end
D = (squeeze(V(1,,:))*P(1) < squeeze(V(2,,:))*P(2));
%END Parzen
```

```
function p = phi(val)
%The window function for the Parzen window
p = (abs(val) <= 0.5);
```

Parzen窗法的决策面





数据



决策面
(图中红色线条为Bayes决策面)

6.6 Kn近邻法

- * Parzen窗估计中存在一个具体问题是体积序列 V_1, V_2, \dots, V_n 的选择问题。
- * k_n 近邻法的基本思想是使体积为数据的函数，而不是样本数目 n 的函数。




6.7 最近邻决策规则

- * 最初的近邻法由Cover和Hart于1968年提出。至今仍是模式分类非参数法中最重要的方法之一。

假定有 C 个模式类别 $\omega_1, \omega_2, \dots, \omega_i, \dots, \omega_C$ 。训练样本集有 N 个样本，每个样本记做 $x_j, j = 1, 2, \dots, N$ 。若

$$d(x, x_k) = \min_j [d(x, x_j)]$$

且 $x_k \in \omega_j$ ，则判 $x \in \omega_j$



6.8 kNN决策规则

假定有 C 个模式类别 $\omega_1, \omega_2, \dots, \omega_i, \dots, \omega_C$ 。训练样本集有 N 个样本，每个样本记做 $x_j, j = 1, 2, \dots, N$ 。

记未知样本为 x 。计算 x 与所有样本的距离，得到 x 与已知样本集合中样本的距离集合


$$D = \{d(x, x_k) | k = 1, 2, \dots, N\}$$

或，记做

$$D = \{d_1, d_2, \dots, d_N\}$$

将 D 按从小到大排序，取前 k 个最小元素及对应样本的类别标签，构成集合 $\Omega(k)$ 。
若在 $\Omega(k)$ 中出现最多的类别为 ω_j ，则判

$$x \in \omega_j$$



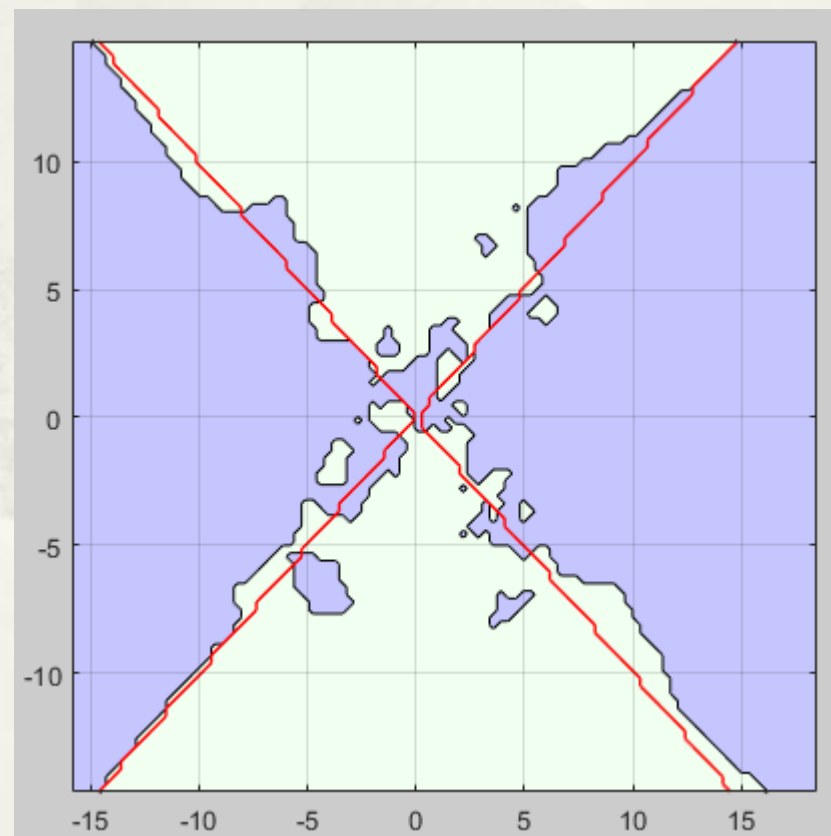

6.9 KNN算法实现


```
1 function D = Nearest_Neighbor(train_features, train_targets, Knn, region)
2
3 % Classify using the Nearest neighbor algorithm
4 % Inputs:
5 %   features    - Train features
6 %   targets     - Train targets
7 %   Knn         - Number of nearest neighbors
8 %   region      - Decision region vector: [-x x -y y number_of_points]
9 %
10 % Outputs
11 %   D           - Decision suface
12
13 L         = length(train_targets);
14 N         = region(5);
15 x         = linspace (region(1),region(2),N);
16 y         = linspace (region(3),region(4),N);
17
18 D         = zeros(N);
19
20 if (L < Knn),
21     error('You specified more neighbors than there are points.')
22 end
23
24 y_dist = (ones(N,1) * train_features(2,:) - y*ones(1,L)).^2;
25
26 for i = 1:N,
27     if (i/50 == floor(i/50)),
28         disp(['Finished ' num2str(i) ' lines out of ' num2str(N) ' lines.'])
29     end
30
31     x_dist = ones(N,1) * (train_features(1,:)-x(i)).^2;
32     dist = abs(x_dist + y_dist);
33     [sorted_dist, indices] = sort(dist);
34     k_nearest = train_targets(indices(1:Knn,:));
35     if (Knn > 1),
36         D(:,i) = (sum(k_nearest) > Knn/2)';
37     else
38         D(:,i) = (k_nearest > 0)';
39     end
40
41 end
```


kNN决策规则的错误率


$$P^* \leq P_e \leq P^* \left(2 - \frac{C}{C-1} P^* \right) \quad \text{其中, } P^* \text{ 表示Bayes错误率, } C \text{ 表示类别数目。}$$

也可粗略地表示为 $P^* \leq P_e \leq 2 P^*$





ID3



C4.5

6.10 剪辑近邻法

设 N 个样本分成 C 类，并用集合 $\mathbb{X}^N = \{\mathbb{X}_1^{N_1}, \mathbb{X}_2^{N_2}, \dots, \mathbb{X}_C^{N_C}\}$ 表示，其中每一类表示为 $\mathbb{X}_i^{N_i} = \{x_i^k\}$ ， $i = 1, 2, \dots, C$ ， $k = 1, 2, \dots, N_i$ 。

方法的第一步：

利用已知集 \mathbb{X}^N 中的样本进行预分类，并剪辑掉被错分类的样本。留下的样本构成剪辑样本集 \mathbb{X}^{NE} 。显然， \mathbb{X}^{NE} 中的样本数比 \mathbb{X}^N 中的少。称之为剪辑。

方法的第二步：

利用剪辑样本集 \mathbb{X}^{NE} 近邻规则对未知样本 x 进行分类。

6.11 压缩近邻法

压缩近邻法旨在进一步缩短计算时间和降低存储要求。

对于 \mathbb{X}^N ，把第1个样本放入STORE中，其余放入GARBBAG。

Step 1.

用当前STORE中样本以1NN对的第 i 个样本分类。

若正确，则该样本仍送回GARBBAG；否则放入STORE。

对GARBBAG中样本重复以上过程。

Step 2.

若GARBBAG中所有样本在上述检验中没有一个样本从GARBBAG中转入STORE，

或者GARBBAG = $\{\emptyset\}$ ，算法终止。

否则，转Step 1。

7. 错误率（再一次讨论）

错误率是分类问题固有复杂性的一种度量，是比较各种模式识别方案好坏的标准。

已经讨论过，对于二类问题用最小错误率Bayes决策规则时，其错误率为

$$\begin{aligned} P(e) &= \int_{-\infty}^t p(x|\omega_2)p(\omega_2)dx + \int_t^{+\infty} p(x|\omega_1)p(\omega_1)dx \\ &= P(\omega_2)P_2(e) + P(\omega_1)P_1(e) \end{aligned}$$

理论上，只要知道先验概率和类条件概率密度，就可以计算错误率。然而，当是多维向量时，需要计算多重积分，往往变得十分复杂，实际上难以进行。因此，

- (1) 按理论公式计算；（某些简单情况下）
- (2) 计算错误率上限；（稍微复杂一些的情况下）
- (3) 通过实验进行评估。

训练集和测试集 (用iris数据示例)

1	5.1,3.5,1.4,0.2,Iris-setosa	51	7.0,3.2,4.7,1.4,Iris-versicolor	101	6.3,3.3,6.0,2.5,Iris-virginica
2	4.9,3.0,1.4,0.2,Iris-setosa	52	6.4,3.2,4.5,1.5,Iris-versicolor	102	5.8,2.7,5.1,1.9,Iris-virginica
3	4.7,3.2,1.3,0.2,Iris-setosa	53	6.9,3.1,4.9,1.5,Iris-versicolor	103	7.1,3.0,5.9,2.1,Iris-virginica
4	4.6,3.1,1.5,0.2,Iris-setosa	54	5.5,2.3,4.0,1.3,Iris-versicolor	104	6.3,2.9,5.6,1.8,Iris-virginica
5	5.0,3.6,1.4,0.2,Iris-setosa	55	6.5,2.8,4.6,1.5,Iris-versicolor	105	6.5,3.0,5.8,2.2,Iris-virginica
6	5.4,3.9,1.7,0.4,Iris-setosa	56	5.7,2.8,4.5,1.3,Iris-versicolor	106	7.6,3.0,6.6,2.1,Iris-virginica
7	4.6,3.4,1.4,0.3,Iris-setosa	57	6.3,3.4,4.7,1.6,Iris-versicolor	107	4.9,2.5,4.5,1.7,Iris-virginica
8	5.0,3.4,1.5,0.2,Iris-setosa	58	4.9,2.4,3.3,1.0,Iris-versicolor	108	7.3,2.9,6.3,1.8,Iris-virginica
9	4.4,2.9,1.4,0.2,Iris-setosa	59	6.6,2.9,4.6,1.3,Iris-versicolor	109	6.7,2.5,5.8,1.8,Iris-virginica
10	4.9,3.1,1.5,0.1,Iris-setosa	60	5.2,2.7,3.9,1.4,Iris-versicolor	110	7.2,3.6,6.1,2.5,Iris-virginica
11	5.4,3.7,1.5,0.2,Iris-setosa	61	5.0,2.0,3.5,1.0,Iris-versicolor	111	6.5,3.2,5.1,2.0,Iris-virginica
12	4.8,3.4,1.6,0.2,Iris-setosa	62	5.9,3.0,4.2,1.5,Iris-versicolor	112	6.4,2.7,5.3,1.9,Iris-virginica
13	4.8,3.0,1.4,0.1,Iris-setosa	63	6.0,2.2,4.0,1.0,Iris-versicolor	113	6.8,3.0,5.5,2.1,Iris-virginica
14	4.3,3.0,1.1,0.1,Iris-setosa	64	6.1,2.9,4.7,1.4,Iris-versicolor	114	5.7,2.5,5.0,2.0,Iris-virginica
15	5.8,4.0,1.2,0.2,Iris-setosa	65	5.6,2.9,3.6,1.3,Iris-versicolor	115	5.8,2.8,5.1,2.4,Iris-virginica
16	5.7,4.4,1.5,0.4,Iris-setosa	66	6.7,3.1,4.4,1.4,Iris-versicolor	116	6.4,3.2,5.3,2.3,Iris-virginica
17	5.4,3.9,1.3,0.4,Iris-setosa	67	5.6,3.0,4.5,1.5,Iris-versicolor	117	6.5,3.0,5.5,1.8,Iris-virginica
18	5.1,3.5,1.4,0.3,Iris-setosa	68	5.8,2.7,4.1,1.0,Iris-versicolor	118	7.7,3.8,6.7,2.2,Iris-virginica
19	5.7,3.8,1.7,0.3,Iris-setosa	69	6.2,2.2,4.5,1.5,Iris-versicolor	119	7.7,2.6,6.9,2.3,Iris-virginica
20	5.1,3.8,1.5,0.3,Iris-setosa	70	5.6,2.5,3.9,1.1,Iris-versicolor	120	6.0,2.2,5.0,1.5,Iris-virginica
21	5.4,3.4,1.7,0.2,Iris-setosa	71	5.9,3.2,4.8,1.8,Iris-versicolor	121	6.9,3.2,5.7,2.3,Iris-virginica
22	5.1,3.7,1.5,0.4,Iris-setosa	72	6.1,2.8,4.0,1.3,Iris-versicolor	122	5.6,2.8,4.9,2.0,Iris-virginica
23	4.6,3.6,1.0,0.2,Iris-setosa	73	6.3,2.5,4.9,1.5,Iris-versicolor	123	7.7,2.8,6.7,2.0,Iris-virginica
24	5.1,3.3,1.7,0.5,Iris-setosa	74	6.1,2.8,4.7,1.2,Iris-versicolor	124	6.3,2.7,4.9,1.8,Iris-virginica
25	4.8,3.4,1.9,0.2,Iris-setosa	75	6.4,2.9,4.3,1.3,Iris-versicolor	125	6.7,3.3,5.7,2.1,Iris-virginica
26	5.0,3.0,1.6,0.2,Iris-setosa	76	6.6,3.0,4.4,1.4,Iris-versicolor	126	7.2,3.2,6.0,1.8,Iris-virginica
27	5.0,3.4,1.6,0.4,Iris-setosa	77	6.8,2.8,4.8,1.4,Iris-versicolor	127	6.2,2.8,4.8,1.8,Iris-virginica
28	5.2,3.5,1.5,0.2,Iris-setosa	78	6.7,3.0,5.0,1.7,Iris-versicolor	128	6.1,3.0,4.9,1.8,Iris-virginica
29	5.2,3.4,1.4,0.2,Iris-setosa	79	6.0,2.9,4.5,1.5,Iris-versicolor	129	6.4,2.8,5.6,2.1,Iris-virginica
30	4.7,3.2,1.6,0.2,Iris-setosa	80	5.7,2.6,3.5,1.0,Iris-versicolor	130	7.2,3.0,5.8,1.6,Iris-virginica
31	4.8,3.1,1.6,0.2,Iris-setosa	81	5.5,2.4,3.8,1.1,Iris-versicolor	131	7.4,2.8,6.1,1.9,Iris-virginica
32	5.4,3.4,1.5,0.4,Iris-setosa	82	5.5,2.4,3.7,1.0,Iris-versicolor	132	7.9,3.8,6.4,2.0,Iris-virginica
33	5.2,4.1,1.5,0.1,Iris-setosa	83	5.8,2.7,3.9,1.2,Iris-versicolor	133	6.4,2.8,5.6,2.2,Iris-virginica
34	5.5,4.2,1.4,0.2,Iris-setosa	84	6.0,2.7,5.1,1.6,Iris-versicolor	134	6.3,2.8,5.1,1.5,Iris-virginica
35	4.9,3.1,1.5,0.1,Iris-setosa	85	5.4,3.0,4.5,1.5,Iris-versicolor	135	6.1,2.6,5.6,1.4,Iris-virginica
36	5.0,3.2,1.2,0.2,Iris-setosa	86	6.0,3.4,4.5,1.6,Iris-versicolor	136	7.7,3.0,6.1,2.3,Iris-virginica
37	5.5,3.5,1.3,0.2,Iris-setosa	87	6.7,3.1,4.7,1.5,Iris-versicolor	137	6.3,3.4,5.6,2.4,Iris-virginica
38	4.9,3.1,1.5,0.1,Iris-setosa	88	6.3,2.3,4.4,1.3,Iris-versicolor	138	6.4,3.1,5.5,1.8,Iris-virginica
39	4.4,3.0,1.3,0.2,Iris-setosa	89	5.6,3.0,4.1,1.3,Iris-versicolor	139	6.0,3.0,4.8,1.8,Iris-virginica
40	5.1,3.4,1.5,0.2,Iris-setosa	90	5.5,2.5,4.0,1.3,Iris-versicolor	140	6.9,3.1,5.4,2.1,Iris-virginica
41	5.0,3.5,1.3,0.3,Iris-setosa	91	5.5,2.6,4.4,1.2,Iris-versicolor	141	6.7,3.1,5.6,2.4,Iris-virginica
42	4.5,2.3,1.3,0.3,Iris-setosa	92	6.1,3.0,4.6,1.4,Iris-versicolor	142	6.9,3.1,5.1,2.3,Iris-virginica
43	4.4,3.2,1.3,0.2,Iris-setosa	93	5.8,2.6,4.0,1.2,Iris-versicolor	143	5.8,2.7,5.1,1.9,Iris-virginica
44	5.0,3.5,1.6,0.6,Iris-setosa	94	5.0,2.3,3.3,1.0,Iris-versicolor	144	6.8,3.2,5.9,2.3,Iris-virginica
45	5.1,3.8,1.9,0.4,Iris-setosa	95	5.6,2.7,4.2,1.3,Iris-versicolor	145	6.7,3.3,5.7,2.5,Iris-virginica
46	4.8,3.0,1.4,0.3,Iris-setosa	96	5.7,3.0,4.2,1.2,Iris-versicolor	146	6.7,3.0,5.2,2.3,Iris-virginica
47	5.1,3.8,1.6,0.2,Iris-setosa	97	5.7,2.9,4.2,1.3,Iris-versicolor	147	6.3,2.5,5.0,1.9,Iris-virginica
48	4.6,3.2,1.4,0.2,Iris-setosa	98	6.2,2.9,4.3,1.3,Iris-versicolor	148	6.5,3.0,5.2,2.0,Iris-virginica
49	5.3,3.7,1.5,0.2,Iris-setosa	99	5.1,2.5,3.0,1.1,Iris-versicolor	149	6.2,3.4,5.4,2.3,Iris-virginica
50	5.0,3.3,1.4,0.2,Iris-setosa	100	5.7,2.8,4.1,1.3,Iris-versicolor	150	5.9,3.0,5.1,1.8,Iris-virginica

7.1交叉验证法(Cross Validation)

交叉验证法是目前常用的实验验证方法。对于训练集中 N 个样本，将其伪随机地划分为 K 个大小相同的子集，且每个子集中先验概率相同。

取其中的一个子集为测试集，另外 $(K - 1)$ 作为训练集。



记录每个测试集上被错分的样本个数 ε_i 。这样顺次将 K 个子集都测试一遍，得到 ε_i ($i = 1, 2, \dots, K$)。总的分类错误率计算为

$$err\% = \frac{\sum_{i=1}^K \varepsilon_i}{N}$$

以上为1次CV-K测试。

取 n 次CV-K测试的平均值作为分类器性能的错误率评测依据。

7.2 留一法(Let One Out)

对于 N 个样本，每次取出1个样本作为测试样本，其它 $(N - 1)$ 个供训练用。 N 次计算后得到错分样本总数 ε 与 N 的比值作为评判依据。即，

$$err\% = \frac{\varepsilon}{N}$$

